

**МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ
РОССИЙСКОЙ ФЕДЕРАЦИИ**

**ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО
ОБРАЗОВАНИЯ
«НОВОСИБИРСКИЙ НАЦИОНАЛЬНЫЙ
ИССЛЕДОВАТЕЛЬСКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ»
ФАКУЛЬТЕТ ИНФОРМАЦИОННЫХ ТЕХНОЛОГИЙ**

Кафедра Систем информатики

Направление подготовки 09.06.01 – Информатика и вычислительная техника

ОТЧЕТ

Обучающегося Якутиной Светланы Александровны группы № 22215 курса 4
(Ф.И.О. полностью)

Тема задания: Построение эмбедингов фрагментов текста

Новосибирск 2025

Оглавление

Введение	3
Реализация построения эмбедингов текста.....	4
Реализация REST-эндпоинтов	6
Заключение.....	7

Введение

Целью данной лабораторной работы является реализация методов построения эмбедингов фрагментов текста и их сравнения в рамках веб-проекта на базе фреймворка Django.

Для достижения поставленной цели были определены следующие задачи:

- реализовать функцию разбиения текста на фрагменты (`get_chunks`);
- реализовать функцию генерации эмбедингов текстов (`get_embeddings`);
- реализовать функцию сравнения двух эмбедингов с использованием косинусного сходства (`cos_compare`);
- интегрировать реализованные функции в проект Django с возможностью работы с текстами, хранящимися в базе данных;
- реализовать эндпоинты для взаимодействия с реализованными функциями.

Реализация построения эмбедингов текста

В рамках лабораторной работы были реализованы функции для обработки текстовых данных и работы с эмбедингами.

Функция `get_chunks` предназначена для разбиения входного текста или списка текстов на отдельные фрагменты фиксированного размера. Данная функция используется для последующей обработки длинных текстов.

Функция `get_embeddings` выполняет генерацию векторных представлений текста с использованием предобученной модели `paraphrase-multilingual-mpnet-base-v2`. Полученные эмбединги используются для хранения в базе данных и дальнейшего анализа.

Функция `cos_compare` реализует сравнение двух эмбедингов с использованием косинусного сходства.

Пример реализации функции разбиения текста на фрагменты приведён на листинге 1.

```
def get_chunks(
    text: str,
    chunk_size: int = 300,
    overlap: int = 50
) -> List[str]:

    if not text:
        return []

    words = text.split()
    chunks = []

    start = 0
    while start < len(words):
        end = start + chunk_size
        chunk = " ".join(words[start:end])
        chunks.append(chunk)
        start += chunk_size - overlap

    return chunks
```

Листинг 1 – Фрагмент кода функции разбиения текста на фрагменты

В процессе работы функции происходит преобразование текстовых данных в числовые векторы фиксированной размерности.

Для интеграции с проектом Django вычисление эмбедингов было добавлено в метод `save` модели текста, что обеспечивает автоматическое сохранение эмбединга в базе данных при добавлении или обновлении записи.

Реализация REST-эндпоинтов

Для проверки и использования реализованного алгоритма в проекте Django были разработаны REST-эндпоинты.

Эндпоинт для генерации эмбеддингов принимает текстовые данные от пользователя, выполняет разбиение текста на фрагменты и возвращает соответствующие эмбеддинги.

Эндпоинт для сравнения эмбеддингов принимает два текстовых фрагмента или их идентификаторы, вычисляет эмбеддинги и возвращает значение косинусного сходства.

Использование эндпоинтов позволяет тестировать работу алгоритма с помощью HTTP-запросов, а также обеспечивает возможность дальнейшей интеграции с внешними сервисами.

Пример реализации эндпоинта для сравнения эмбеддингов текстов приведён на листинге 2.

```
def cos_compare(request):
    data = request.data
    vec1 = data.get("vec1")
    vec2 = data.get("vec2")
    text1_id = data.get("text1_id")
    text2_id = data.get("text2_id")

    # Получаем эмбеддинги из текстов в базе, если переданы text_id
    if text1_id:
        try:
            text_obj = Text.objects.get(id=text1_id)
            vec1 = text_obj.embedding
        except Text.DoesNotExist:
            return Response({"error": "Text1 not found"}, status=404)

    if text2_id:
        try:
            text_obj = Text.objects.get(id=text2_id)
            vec2 = text_obj.embedding
        except Text.DoesNotExist:
            return Response({"error": "Text2 not found"}, status=404)

    if vec1 is None or vec2 is None:
        return Response({"error": "Missing vectors or text_ids"}, status=400)

    similarity = EmbeddingUtils.cos_compare(vec1, vec2)
    return Response({"cosine_similarity": similarity}, status=200)
```

Листинг 2 – Эндпоинт для сравнения эмбеддингов текстов.

Заключение

В результате выполнения лабораторной работы были реализованы все поставленные задачи. Были разработаны функции для построения и сравнения эмбеддингов, а также реализованы REST-эндпоинты для взаимодействия с ними. Алгоритм успешно интегрирован в проект Django и работает с текстами, хранящимися в базе данных.